PROJET PYTHON AVANCÉ (WEBSCRAPING)

Analyse du marché immobilier français (Webapp Streamlit)

Sorbonne Data Analytics
2025/2026

Constance KEITA / Guillaume PATIENT

tinamarie@hotmail.fr / gpat171@gmail.com

Table des matières

1. Introduction *3*

2. Contexte et enjeu du projet *3*

2.1 Objectifs techniques 4

2.2 Objectifs analytiques 4

2.3 Livrables 4

3. État de l'art *5*

3.1. Analyse du marché immobilier par les données 5

3.2. Web scraping comme méthode de collecte de données 5

3.3. Nettoyage et préparation des données textuelles 6

3.4. Extraction d'informations à partir de textes non structurés 6

3.5. Enrichissement par des référentiels externes 6

3.6. Indicateurs statistiques et analyse exploratoire 7

3.7. Visualisation interactive et outils de restitution 7

3.8. Positionnement du projet par rapport à l'état de l'art 7

4. Données et sources *8*

5. Méthodologie *8*

5.1 Collecte et extraction 8

5.2 Nettoyage et normalisation 8

5.3 Enrichissement géographique 9

5.4 Identification des biens neufs et anciens 9

5.5 Calcul des indicateurs 9

5.6 Géocodage des communes à l'aide de Nominatim (geopy) 10

6. Analyse exploratoire *10*

6.1 Disparités régionales du marché immobilier 10

6.2 Analyse à l'échelle des villes 11

6.3 Comparaison entre biens neufs et anciens 12

6.4 Relation entre prix et surface 13

6.5 Apports et limites de l'analyse exploratoire 14

7. Restitution via application Streamlit *15*

7.1 Objectifs de l'application 15

7.2 Architecture générale et organisation des pages 16

7.3 Chargement des données et stratégie de performance 16

7.4 Système de filtres : logique et paramètres 17

7.5 Indicateurs synthétiques (KPI) 17

7.6 Visualisations principales **18**
7.6.1 Prix au m^2 par région (bar chart) 18
7.6.2 Distribution du prix au m^2 (histogramme) 18
7.6.3 Relation prix – surface (scatter plot) 18
7.6.4 Heatmap régionale 18
7.7 Comparaison Neuf / Ancien (région et ville) **19**
7.8 Focus "une ville" : exploration locale **19**
7.9 Choix de conception et limites **19**
7.10 Carte des annonces **20**
7.10.1 Construction de la carte interactive 20
7.10.2 Apports analytiques de la cartographie géocodée 21
7.11 Conclusion sur la restitution **22**
8. Limites du projet ***22***
9. Conclusion ***22***

1. Introduction

L'essor des plateformes numériques a profondément modifié l'accès à l'information immobilière. Chaque jour, des milliers d'annonces sont publiées en ligne, décrivant des biens aux caractéristiques variées, dans des formats hétérogènes et souvent peu normalisés. Ces données constituent une source précieuse pour l'analyse du marché immobilier, à condition de disposer d'outils adaptés pour les collecter, les structurer et les analyser.

Dans ce contexte, le présent projet s'inscrit dans le cadre du module *Python avancé* a pour objectif principal de mettre en œuvre une chaîne complète de traitement de données réelles issues du web. Contrairement à des jeux de données académiques déjà nettoyés, les données utilisées ici sont brutes, imparfaites et parfois incohérentes, ce qui reflète les conditions réelles rencontrées dans des projets professionnels de data analysis.

Le projet vise ainsi à démontrer la capacité à :

- collecter automatiquement des données non structurées,
- extraire des informations pertinentes à partir de textes libres,
- nettoyer et enrichir ces données à l'aide de référentiels officiels,
- réaliser une analyse exploratoire pertinente,
- restituer les résultats sous forme interactive.

Ce projet se distingue par le choix assumé de travailler sur des données imparfaites, reflétant les conditions réelles d'un projet de data analysis. L'accent est ainsi mis non seulement sur l'analyse des résultats, mais également sur la qualité du pipeline de traitement des données, considéré comme un élément central du travail réalisé.

---

2. Contexte et enjeu du projet

L'analyse du marché immobilier est un sujet à fort enjeu économique et social. Les prix des logements varient fortement selon les territoires, les types de biens et leur état (neuf ou ancien). Comprendre ces disparités nécessite de disposer de données suffisamment détaillées et fiables.

Cependant, les données issues des plateformes d'annonces présentent plusieurs défis :

- absence de standardisation des formats,
- informations parfois manquantes ou ambiguës,
- vocabulaire libre utilisé par les annonceurs,
- redondances ou incohérences selon les sources.

Ce projet s'inscrit donc dans une démarche réaliste d'analyse de données, où la qualité des résultats dépend directement de la rigueur appliquée aux étapes de préparation des données.

Ce projet a pour objectif principal de mettre en œuvre une chaîne complète de traitement de données à partir de données réelles issues du web, dans un contexte proche de celui rencontré en entreprise ou en mission de data analysis.

Plus précisément, les objectifs poursuivis sont les suivants :

2.1 Objectifs techniques

- concevoir des scripts Python robustes pour la collecte automatisée de données via le web scraping ;
- manipuler et transformer des données hétérogènes à l'aide des bibliothèques Pandas et NumPy ;
- structurer le code de manière modulaire afin de faciliter sa maintenance et son évolution ;
- gérer des problèmes concrets liés à la qualité des données (valeurs manquantes, incohérences, formats non standardisés).

2.2 Objectifs analytiques

- extraire des informations pertinentes à partir de contenus textuels non structurés ;
- produire des indicateurs descriptifs fiables du marché immobilier, notamment le prix au mètre carré ;
- analyser les disparités géographiques à différentes échelles (région, commune) ;
- comparer, lorsque cela est possible, les marchés du logement neuf et ancien.

2.3 Livrables

- concevoir une application interactive permettant l'exploration dynamique des données ;

- rendre les résultats accessibles à un public non technique ;
- valoriser le travail d'analyse par des visualisations claires et pertinentes.

---

3. État de l'art

3.1. Analyse du marché immobilier par les données

L'analyse du marché immobilier est un domaine largement étudié en économie, en géographie et en science des données. Traditionnellement, ces analyses reposent sur des bases de données institutionnelles, telles que les données notariales, les bases fiscales ou les statistiques produites par les instituts nationaux. Ces sources présentent l'avantage d'une forte fiabilité, mais sont souvent peu accessibles ou publiées avec un important décalage temporel.

Avec le développement du numérique, les plateformes immobilières en ligne sont devenues une source alternative majeure d'information. Elles offrent un accès quasi immédiat à un grand volume de données, permettant d'observer les tendances du marché en temps réel. Cependant, ces données sont produites dans un objectif commercial et non statistique, ce qui pose de nombreux défis méthodologiques.

3.2. Web scraping comme méthode de collecte de données

Le web scraping est une technique largement utilisée pour collecter automatiquement des données accessibles publiquement sur Internet. Dans le domaine immobilier, il est couramment employé pour extraire des annonces à partir de sites spécialisés.(1)

Plusieurs travaux montrent que le scraping permet de constituer rapidement des bases de données volumineuses et régulièrement mises à jour. Toutefois, cette approche implique des contraintes techniques (structures HTML variables, limitations d'accès) et éthiques (respect des conditions d'utilisation des sites).(2)(3)

Dans un cadre académique, le scraping est généralement utilisé à des fins exploratoires ou pédagogiques, notamment pour illustrer des problématiques de nettoyage et de structuration de données réelles.

3.3. Nettoyage et préparation des données textuelles

La préparation des données constitue une étape essentielle dans tout projet de data analysis. Les données issues du web sont souvent qualifiées de *données bruitées*, car elles contiennent des erreurs, des incohérences et des valeurs manquantes.

Les travaux en science des données soulignent que le nettoyage peut représenter une part majoritaire du temps total d'un projet analytique. Cette étape comprend notamment :

- la normalisation des formats,
- la gestion des valeurs manquantes,
- la détection d'anomalies,
- l'harmonisation des variables catégorielles.

Dans le cas des annonces immobilières, la difficulté réside principalement dans l'extraction d'informations structurées à partir de textes libres.

3.4. Extraction d'informations à partir de textes non structurés

L'extraction d'informations à partir de textes non structurés est un domaine situé à l'interface entre le traitement automatique du langage naturel (NLP) et la science des données.

Dans des contextes simples ou à petite échelle, des approches basées sur des règles et des expressions régulières sont souvent privilégiées. Elles offrent une bonne interprétabilité et un contrôle précis du comportement des algorithmes, au prix d'une sensibilité aux variations d'écriture.

Dans des projets plus avancés, des méthodes de NLP supervisées ou non supervisées peuvent être utilisées, mais elles nécessitent des jeux de données annotés et une complexité accrue, souvent incompatible avec un cadre pédagogique.

3.5. Enrichissement par des référentiels externes

L'enrichissement des données à l'aide de référentiels externes est une pratique courante en data management. Dans le cas des données géographiques, des référentiels tels que ceux fournis par l'INSEE ou La Poste permettent de fiabiliser les informations de localisation.

Ces référentiels assurent une cohérence entre les différentes échelles territoriales (communes, départements, régions) et facilitent les analyses comparatives. Leur utilisation est particulièrement pertinente lorsque les données sources sont incomplètes ou ambiguës.

3.6. Indicateurs statistiques et analyse exploratoire

L'analyse exploratoire des données vise à comprendre la structure d'un jeu de données avant toute modélisation. Elle repose principalement sur des statistiques descriptives et des visualisations.

Dans le domaine immobilier, les indicateurs les plus couramment utilisés sont :

- le prix moyen ou médian,
- le prix au mètre carré,
- la dispersion des prix,
- les comparaisons territoriales.

La médiane est souvent privilégiée à la moyenne afin de limiter l'influence des valeurs extrêmes, fréquentes dans les données immobilières.

3.7. Visualisation interactive et outils de restitution

La visualisation des données joue un rôle central dans l'analyse et la communication des résultats. Les outils de visualisation interactive, tels que Streamlit, permettent de rendre les analyses accessibles à un public plus large.

Contrairement à des graphiques statiques, les interfaces interactives offrent la possibilité de filtrer dynamiquement les données, d'explorer différentes échelles géographiques et de comparer des sous-ensembles spécifiques. Cette approche est de plus en plus utilisée dans les projets de data science à vocation pédagogique ou exploratoire.

3.8. Positionnement du projet par rapport à l'état de l'art

Le présent projet s'inscrit dans une démarche exploratoire et pédagogique, en cohérence avec les pratiques actuelles de la science des données. Il mobilise des méthodes classiques mais robustes, adaptées à des données réelles issues du web.

Sans viser une modélisation prédictive avancée, le projet met l'accent sur la qualité du nettoyage, l'enrichissement des données et la restitution interactive, éléments essentiels pour produire des analyses fiables et interprétables.

---

4. Données et sources

Les données utilisées dans ce projet proviennent de plusieurs plateformes immobilières françaises. Chaque annonce contient notamment :

- un titre et une description textuelle,
- un prix affiché,
- une surface habitable,
- un nombre de pièces,
- une localisation plus ou moins précise,
- une source (plateforme d'origine).

Ces données présentent de fortes disparités de format selon la plateforme, ce qui justifie la mise en place d'un pipeline de nettoyage spécifique.

---

5. Méthodologie

5.1 Collecte et extraction

La collecte des données est réalisée par des scripts Python dédiés au scraping. Les annonces sont stockées dans un fichier brut au format CSV. Les champs textuels sont ensuite analysés à l'aide d'expressions régulières afin d'extraire les informations quantitatives suivantes :

- prix du bien,
- surface habitable,
- nombre de pièces,
- code postal lorsqu'il est présent dans le texte.

5.2 Nettoyage et normalisation

Les données extraites font l'objet de plusieurs étapes de nettoyage :

- suppression des caractères parasites et des espaces insécables,
- conversion des variables numériques vers des types adaptés,
- normalisation des codes postaux sur 5 chiffres,
- harmonisation des noms de villes (règle du premier mot).

Un mécanisme de rattrapage est mis en place pour compléter les codes postaux manquants à partir d'un référentiel interne basé sur les noms de communes.

5.3 Enrichissement géographique

Afin d'améliorer la fiabilité des informations de localisation, un référentiel officiel des communes françaises (codes postaux, noms de communes, codes INSEE) est utilisé. Une jointure est réalisée entre les annonces et ce référentiel afin d'ajouter :

- le nom officiel de la commune associé au code postal,
- le code INSEE lorsque disponible.

La variable *ville finale* est définie comme le nom officiel de la commune lorsque celui-ci est connu, sinon comme la ville extraite depuis l'annonce.

5.4 Identification des biens neufs et anciens

Une distinction entre biens neufs et anciens est effectuée à partir du titre des annonces. Cette classification repose sur une approche heuristique basée sur des mots-clés (par exemple : *neuf*, *VEFA*, *programme*, *à rénover*, *travaux*).

Lorsque les indices sont contradictoires ou absents, la catégorie est laissée indéterminée afin d'éviter toute surinterprétation.

5.5 Calcul des indicateurs

Le prix au mètre carré est calculé pour chaque annonce à partir du prix et de la surface habitable, lorsque ces deux informations sont disponibles. Des indicateurs statistiques descriptifs sont ensuite produits :

- médiane et moyenne du prix au m²,
- distributions par région et par commune,
- comparaisons entre marchés du neuf et de l'ancien.

5.6 Géocodage des communes à l'aide de Nominatim (geopy)

(https://operations.osmfoundation.org/)

Afin de permettre une représentation cartographique des données, un travail de géocodage a été réalisé à partir des informations de localisation disponibles dans les annonces. Ce géocodage repose sur l'utilisation de la bibliothèque **geopy**, qui fournit une interface Python vers le service **Nominatim** basé sur OpenStreetMap.

Le principe consiste à convertir des informations textuelles de localisation (nom de commune, code postal, région) en coordonnées géographiques (latitude, longitude). Ces coordonnées sont ensuite utilisées pour positionner les données sur une carte interactive.(4)

Dans le cadre de ce projet, le géocodage a été réalisé principalement à l'échelle des communes ou des régions, et non à l'adresse précise, afin de :

- limiter les appels à l'API Nominatim,
- respecter les contraintes d'usage du service,
- garantir un temps de traitement raisonnable.

Lorsque le géocodage n'a pas pu être réalisé de manière fiable (commune ambiguë, information manquante), les données correspondantes ont été exclues de la cartographie, mais conservées pour les analyses statistiques non spatiales.

---

6. Analyse exploratoire

L'analyse exploratoire constitue une étape centrale du projet, car elle permet de dégager les grandes tendances du marché immobilier à partir des données collectées et nettoyées, sans recourir à des modèles prédictifs. Elle repose principalement sur des statistiques descriptives et des visualisations interactives, afin de mieux comprendre la structure des données et d'identifier des disparités territoriales.

6.1 Disparités régionales du marché immobilier

L'analyse à l'échelle régionale met en évidence des disparités marquées en termes de prix au mètre carré. Les régions les plus urbanisées et économiquement attractives présentent des

niveaux de prix sensiblement plus élevés que les régions à dominante rurale ou moins densément peuplées. (Figure.1)

Cette observation est cohérente avec les dynamiques connues du marché immobilier français, où la pression foncière, la densité de population et l'attractivité économique jouent un rôle déterminant dans la formation des prix. L'utilisation du **prix au mètre carré médian** permet de limiter l'influence des annonces atypiques, notamment les biens de prestige ou les annonces comportant des valeurs extrêmes.

Il convient toutefois de souligner que la robustesse des indicateurs régionaux dépend directement du nombre d'annonces disponibles. C'est pourquoi les effectifs sont systématiquement pris en compte dans l'interprétation des résultats.

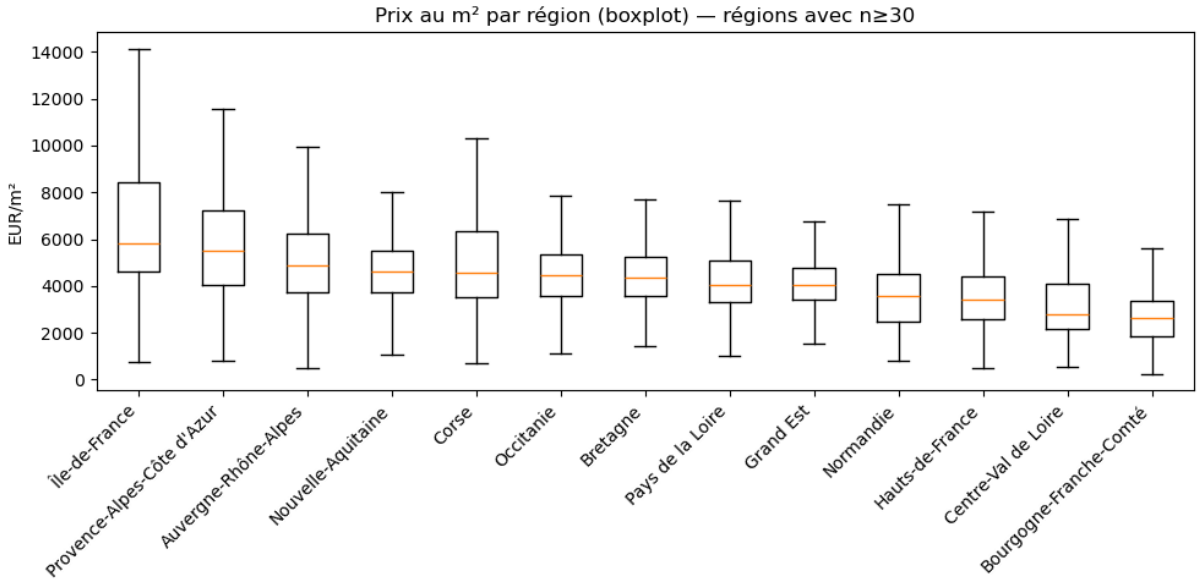

Figure 1 : Comparaison du prix/m^2 par région

6.2 Analyse à l'échelle des villes

À une échelle plus fine, l'analyse par ville révèle une forte hétérogénéité locale, y compris au sein d'une même région. Certaines communes affichent des niveaux de prix au mètre carré nettement supérieurs à la moyenne régionale, tandis que d'autres restent plus accessibles. (Fig.2)

Ces écarts peuvent s'expliquer par plusieurs facteurs, tels que la proximité des pôles d'emploi, l'accessibilité aux transports, ou encore l'attractivité résidentielle. Cette variabilité locale

souligne l'importance de ne pas se limiter à une analyse régionale globale, mais d'examiner également les dynamiques à l'échelle communale.

Afin d'éviter des conclusions basées sur des échantillons trop réduits, les analyses par ville sont généralement limitées aux communes disposant d'un nombre minimal d'annonces.

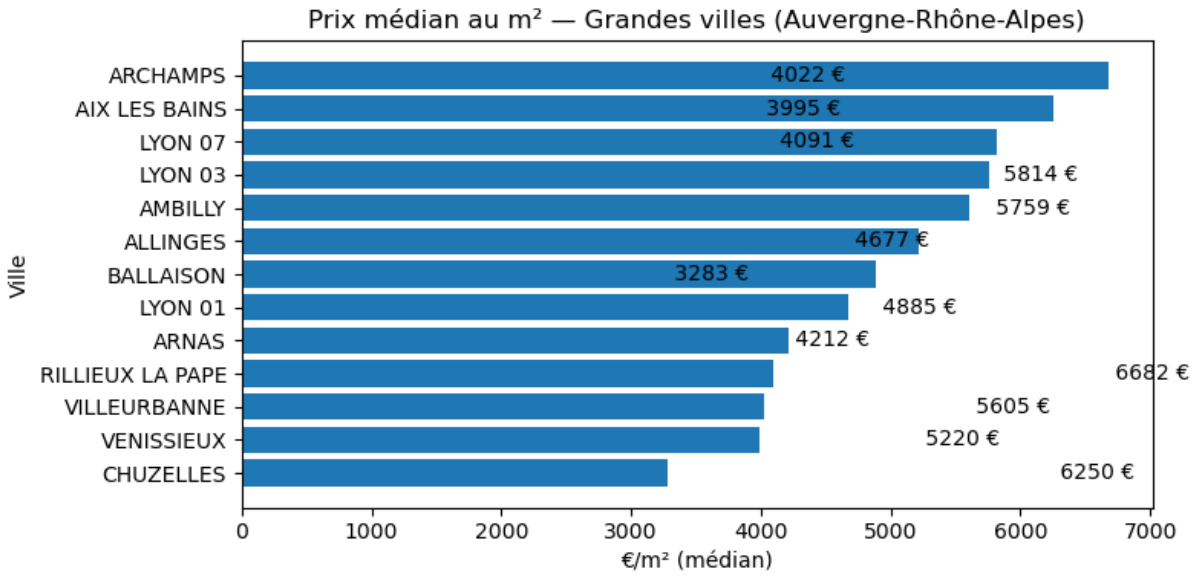

Figure 2 : Comparaison du prix/m^2 pour les grandes villes d'une même région (exemple : Auvergne-Rhône-Alpe)

6.3 Comparaison entre biens neufs et anciens

Lorsque l'information est disponible, une comparaison entre biens neufs et anciens est réalisée à partir du prix au mètre carré. Les résultats montrent généralement un **surcoût du neuf** par rapport à l'ancien, bien que cet écart varie fortement selon les territoires. (Fig.3)

Dans certaines régions ou villes, le différentiel de prix est marqué, traduisant une forte valorisation des constructions récentes, souvent liées à des normes énergétiques plus strictes ou à une offre plus rare. Dans d'autres cas, l'écart est plus faible, voire peu significatif, ce qui peut s'expliquer par la structure locale de l'offre ou par des volumes d'annonces limités.

Il est important de noter que cette comparaison dépend fortement de la taille des échantillons disponibles pour chaque segment. Les résultats doivent donc être interprétés avec prudence, en tenant compte des effectifs associés.

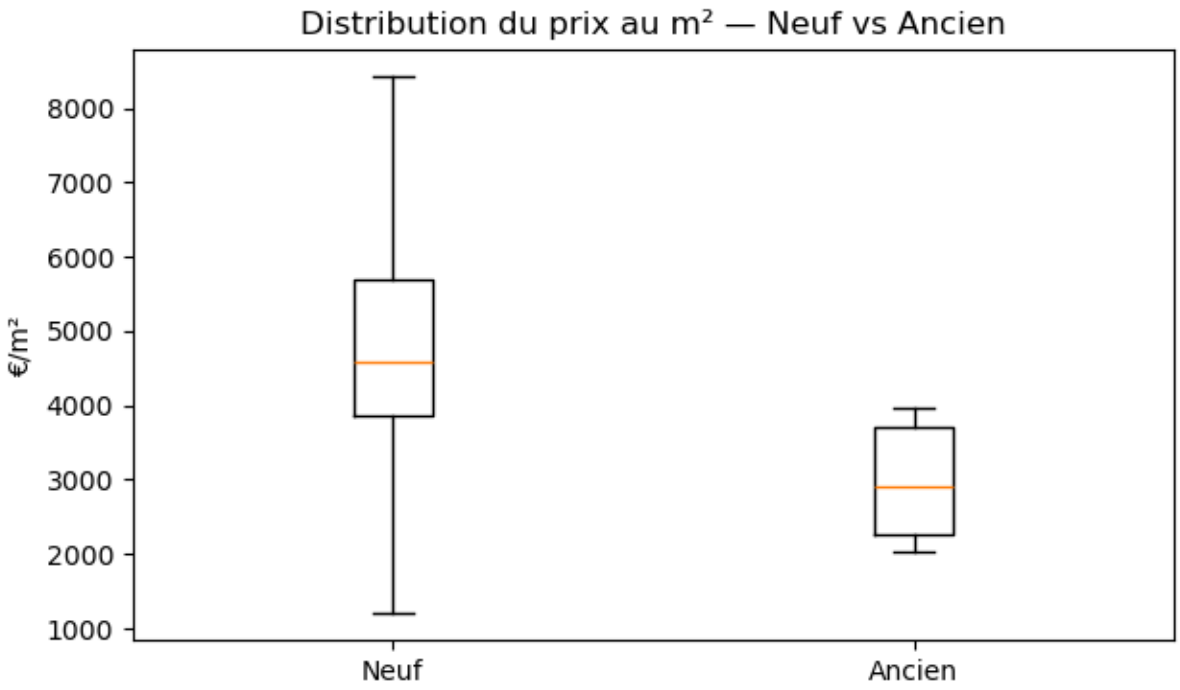

Figure 3 : Écart de prix/m^2 entre les biens neufs et anciens sur la globalité du territoire français

6.4 Relation entre prix et surface

L'analyse de la relation entre le prix total d'un bien et sa surface confirme l'existence d'une corrélation positive : en moyenne, les biens de plus grande surface sont plus chers. Toutefois, cette relation n'est pas strictement linéaire, comme le montrent les nuages de points générés dans l'application. (Fig.4)

Cette non-linéarité s'explique notamment par le fait que le prix au mètre carré tend à diminuer lorsque la surface augmente, en particulier pour les biens de grande taille. Ce phénomène justifie le recours à des indicateurs robustes, tels que la médiane, afin de mieux caractériser le marché immobilier.

Les visualisations permettent également d'identifier certaines annonces atypiques, qui peuvent correspondre à des biens de prestige, à des erreurs d'extraction ou à des situations particulières du marché.

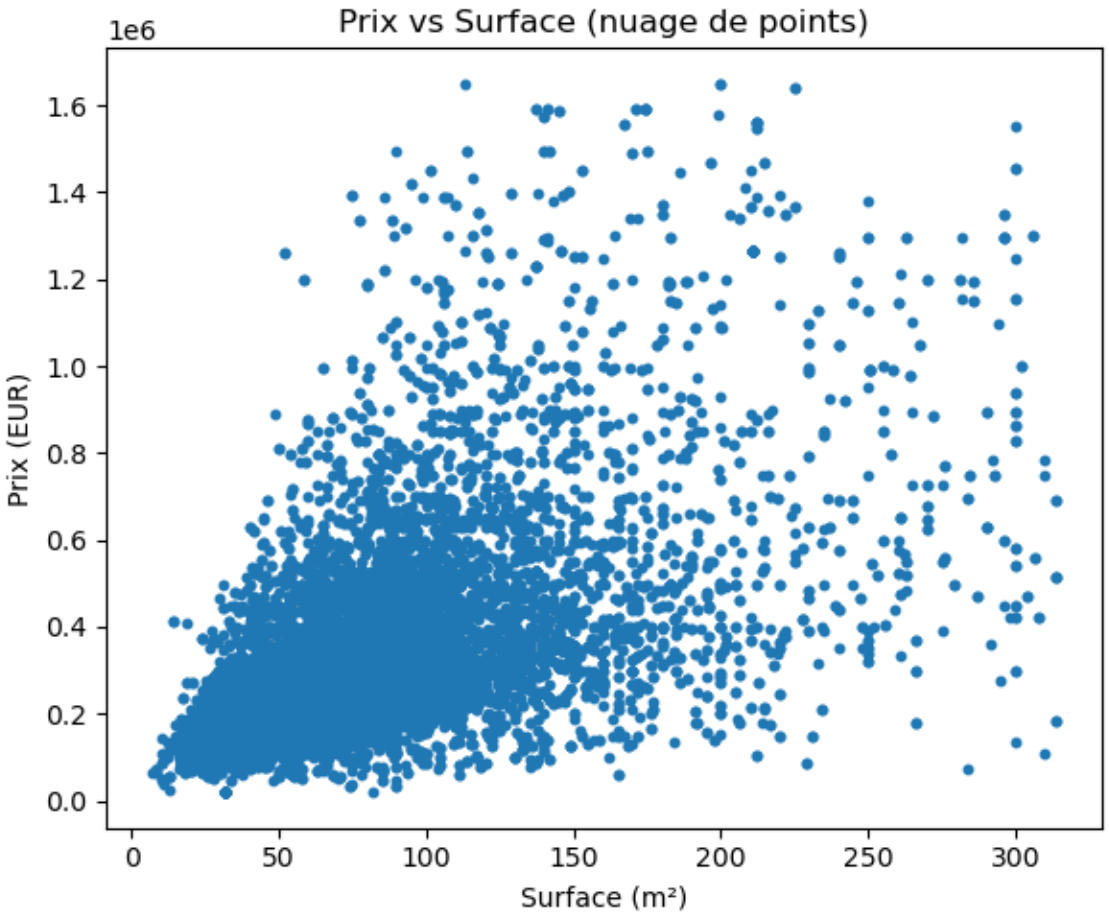

Figure 4 : Corrélation entre le prix et la surface du bien (Corrélation de Pearson =0,56)

6.5 Apports et limites de l'analyse exploratoire

L'analyse exploratoire permet de dégager des tendances générales du marché immobilier et de mettre en évidence des disparités spatiales significatives. Elle constitue une étape essentielle pour comprendre les données avant toute analyse plus avancée.

Néanmoins, les résultats obtenus doivent être interprétés comme une analyse de l'offre immobilière en ligne à un instant donné, et non comme une représentation exhaustive du marché réel. Malgré ces limites, cette approche fournit une base solide pour l'exploration et la compréhension des dynamiques immobilières à différentes échelles géographiques.

7. Web-application Streamlit

Les résultats de l'analyse sont restitués à travers une application interactive développée avec Streamlit. Cette application propose :

- un tableau de bord synthétique avec indicateurs clés,
- des visualisations interactives (histogrammes, nuages de points, cartes, heatmaps),
- des filtres dynamiques par région, ville, source et caractéristiques du bien,
- des comparaisons entre neuf et ancien à différentes échelles géographiques.

Cette approche interactive permet à l'utilisateur d'explorer librement les données et d'adapter l'analyse à ses besoins.

Figure 5 : Page d'accueil de la webapp interactive streamlit

7.1 Objectifs de l'application

L'application Streamlit constitue l'interface principale de restitution du projet. Elle répond à trois objectifs :

1. **Rendre l'analyse accessible** : permettre à un utilisateur non technique d'explorer le marché immobilier à partir d'indicateurs et de visualisations claires.

2. **Faciliter l'exploration interactive** : offrir des filtres permettant de sélectionner un sous-ensemble de données (région, ville, sources, fourchettes de prix et de surface).
3. **Appuyer la démarche analytique** : proposer un tableau de bord synthétique et des visualisations qui aident à identifier des tendances, des écarts et des anomalies.

L'application est conçue pour fonctionner à partir du fichier nettoyé (CSV) généré par le pipeline de préparation des données.

7.2 Architecture générale et organisation des pages

L'application est structurée selon une logique multipage, ce qui permet d'isoler les différents usages (vue d'ensemble, analyses détaillées, focus local). Une organisation typique comprend :

- **Page d'accueil** : présentation du projet, du périmètre des données et des principales fonctionnalités.
- **Tableau de Bord** : vue synthétique avec KPI et principales visualisations.
    - **Analyses territoriales** : visualisations comparatives par région et/ou par ville.
    - **Focus ville** : exploration détaillée d'une commune sélectionnée.
    - **Comparaison Neuf / Ancien** : analyse spécifique des écarts de prix au m² lorsque la variable est disponible.
- **Carte des annonces géolocalisées**

Cette structuration multipage améliore la lisibilité et évite de surcharger une seule page avec trop d'éléments.

7.3 Chargement des données et stratégie de performance

L'application charge le jeu de données nettoyé via une fonction dédiée (ex. load_data()), qui peut être mise en cache avec st.cache_data afin d'améliorer la performance :

- le chargement initial est effectué une seule fois ;
- les filtres et visualisations opèrent ensuite sur une copie filtrée (df_f) ;
- l'application reste fluide même lorsque le jeu de données contient plusieurs milliers de lignes.

Cette stratégie est importante car Streamlit ré-exécute le script à chaque interaction utilisateur (changement de filtre, sélection, etc.), ce qui impose de limiter les opérations coûteuses.

7.4 Système de filtres : logique et paramètres

Une barre latérale (sidebar) permet de filtrer les données de manière interactive. Les filtres proposés correspondent aux variables les plus structurantes du dataset :

- **Régions** : sélection multiple permettant d'observer les disparités territoriales.
- **Sources** : sélection multiple (plateforme d'origine) afin de comparer les effets de source ou limiter à une plateforme.
- **Ville** : champ de recherche textuel (filtre "contient") permettant une recherche flexible.
- **Prix** : slider pour limiter l'analyse à une fourchette de prix.
- **Surface** : slider pour limiter l'analyse à une fourchette de surface.
- **Nombre de pièces** : slider ou intervalle lorsque la variable est disponible.

Ces filtres alimentent une fonction centrale de filtrage (ex. filter_df) qui renvoie un sous-ensemble df_f. L'ensemble des KPI et visualisations est calculé à partir de ce sous-ensemble, garantissant la cohérence de l'exploration.

7.5 Indicateurs synthétiques (KPI)

Le tableau de bord propose en première partie des indicateurs clés permettant d'avoir une vue immédiate du sous-ensemble sélectionné :

- **Nombre d'annonces** : taille de l'échantillon après filtrage.
- **Prix médian** : indicateur robuste à la présence de valeurs extrêmes.
- **Surface médiane** : caractérise la taille typique des biens.
- **Prix au m² médian** : indicateur central du projet.

Le choix de la médiane est motivé par la distribution des prix immobiliers, souvent asymétrique, et la présence d'annonces atypiques (biens de prestige, erreurs d'extraction, etc.).

7.6 Visualisations principales

L'application comprend plusieurs visualisations interactives, conçues pour répondre à des questions analytiques spécifiques.

7.6.1 Prix au m^2 par région (bar chart)

Une visualisation en barres horizontales permet de comparer les régions selon le **prix au m² médian** (et éventuellement la moyenne). Le graphique inclut également les effectifs (n) afin de contextualiser la robustesse des résultats (une région avec peu d'annonces peut produire un indicateur moins stable).

Objectif : identifier rapidement les régions les plus chères et les plus abordables.

7.6.2 Distribution du prix au m^2 (histogramme)

Un histogramme montre la répartition des prix au m² pour l'échantillon filtré. Cette visualisation permet :

- de repérer des distributions asymétriques,
- d'identifier des valeurs extrêmes,
- d'évaluer l'homogénéité d'un marché selon le territoire.

7.6.3 Relation prix – surface (scatter plot)

Un nuage de points représente la relation entre le prix total et la surface (ou, selon le choix, prix au m² et surface). Cette visualisation :

- vérifie la cohérence globale (plus grand → plus cher),
- détecte des annonces aberrantes (prix très élevé pour petite surface, etc.),
- permet d'observer des sous-groupes par région ou par source (via les informations au survol).

Une stratégie d'échantillonnage peut être utilisée au-delà d'un seuil (ex. 3000 points) afin de garder une bonne performance.

7.6.4 Heatmap régionale

Une heatmap permet de visualiser les disparités régionales de façon synthétique. Selon la construction, elle peut représenter :

- le prix au m² médian par région,
- ou un indicateur de dispersion (écart interquartile, variance),
- ou la comparaison Neuf/Ancien par région.

Objectif : donner une lecture “carte mentale” rapide des contrastes territoriaux.

7.7 Comparaison Neuf / Ancien (région et ville)

Lorsque la variable Neuf/Ancien est détectée (à partir de mots-clés), l’application propose une comparaison à deux niveaux :

- **par région** : prix au m² médian en neuf vs ancien, effectifs et écarts en valeur et en pourcentage ;
- **par ville** : même logique, mais avec un filtre min_n afin de ne conserver que les communes où les effectifs sont suffisants pour une comparaison pertinente.

Cette partie est particulièrement utile pour observer si le surcoût du neuf est uniforme ou dépend du territoire.

7.8 Focus “une ville” : exploration locale

Une section dédiée permet à l’utilisateur de sélectionner une ville unique et d’obtenir :

- des KPI spécifiques à cette ville,
- une distribution du prix au m² (histogramme et boxplot),
- une relation prix/surface limitée à la commune.

Cette vue “micro” est complémentaire aux analyses régionales car elle met en évidence des situations locales parfois très différentes des tendances régionales.

7.9 Choix de conception et limites

Plusieurs choix ont été faits afin de maintenir l’application utilisable et interprétable :

- utilisation d’indicateurs robustes (médiane),
- présence systématique des effectifs (n) pour contextualiser les résultats,
- exclusion ou neutralisation des cas où les données sont insuffisantes,

- filtres permettant de limiter les biais de source.

L'application dépend toutefois de la qualité du scraping et du nettoyage. Les résultats présentés doivent donc être interprétés comme une analyse de l'offre en ligne et non comme une mesure exhaustive du marché réel.

7.10 Carte des annonces

Afin d'enrichir l'analyse exploratoire par une dimension spatiale plus fine, une carte interactive a été intégrée à l'application Streamlit. Contrairement à une approche purement régionale, cette carte repose sur le géocodage des communes à partir des données textuelles extraites lors du scraping.

Le géocodage a été réalisé à l'aide de la bibliothèque Geopy, en s'appuyant sur le service de géocodage Nominatim d'OpenStreetMap. Cette solution open source permet de convertir des informations textuelles de localisation (nom de commune, code postal) en coordonnées géographiques (latitude et longitude).

7.10.1 Construction de la carte interactive

Les coordonnées issues du géocodage sont ensuite utilisées pour afficher les annonces sur une carte interactive intégrée à l'application Streamlit. Chaque point correspond à une annonce immobilière ou, selon le niveau d'agrégation choisi, à une commune.

Les indicateurs affichés sur la carte reposent principalement sur le prix au mètre carré, permettant de visualiser les zones où les prix sont les plus élevés ou les plus accessibles. Le survol des points fournit des informations complémentaires telles que :

- le nom de la commune,
- le prix au mètre carré,
- la surface du bien,
- la source de l'annonce.

L'utilisateur peut ainsi explorer visuellement la distribution spatiale des prix immobiliers et identifier des concentrations locales ou des zones de contraste marquées.

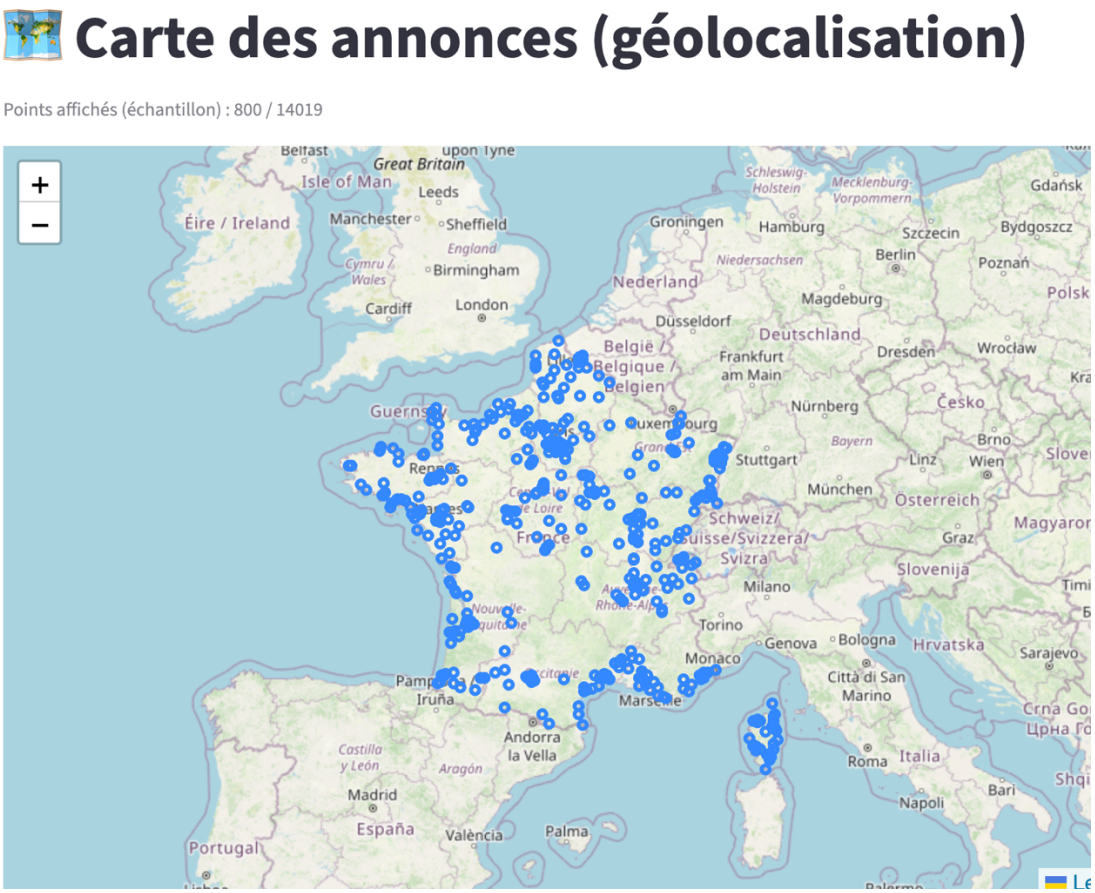

Figure 6 : Carte des localisations des annonces sur le territoire français, collectées et analysées sur la webapp

7.10.2 Apports analytiques de la cartographie géocodée

L'utilisation de Geopy et Nominatim permet d'aller au-delà d'une analyse agrégée par région ou par ville. La carte interactive met en évidence :

- une forte hétérogénéité spatiale, y compris à l'intérieur d'une même région,
- des concentrations de prix élevées autour des grands pôles urbains,
- des écarts significatifs entre communes proches géographiquement.

Cette visualisation apporte une lecture intuitive et complémentaire aux graphiques statistiques, facilitant l'interprétation des résultats pour un utilisateur non spécialiste. (5) La cartographie interactive basée sur le géocodage constitue ainsi un prolongement naturel de l'analyse exploratoire, en reliant les indicateurs immobiliers à leur ancrage spatial.

7.11 Conclusion sur la restitution

L'application Streamlit joue un rôle central dans le projet : elle transforme un travail technique (scraping + cleaning) en un outil d'exploration utilisable. Elle constitue un support pertinent pour la démonstration du projet, car elle permet de naviguer dans les résultats, de vérifier visuellement certaines hypothèses, et de rendre l'analyse accessible.

---

8. Limites du projet

Plusieurs limites doivent être soulignées :

- les données sont issues d'annonces et non de transactions effectives,
- certaines informations sont absentes ou imprécises selon les plateformes,
- la classification neuf/ancien repose sur des règles heuristiques et non sur une vérité terrain.

Le recours au service Nominatim pour le géocodage implique certaines contraintes, notamment en termes de volume de requêtes et de précision des résultats. Par conséquent, le géocodage est volontairement limité à une échelle territoriale agrégée. Cette limitation n'affecte pas la pertinence des analyses régionales, mais constitue un point d'attention pour d'éventuelles extensions futures du projet.

Ces limites impliquent une interprétation prudente des résultats.

---

9. Conclusion

Ce projet a permis de mettre en œuvre un pipeline de traitement de données complet, couvrant l'ensemble des étapes classiques d'un projet de data analysis : collecte automatisée par web scraping, nettoyage et structuration des données, enrichissement géographique, analyse exploratoire et visualisation interactive. Il met en évidence les difficultés inhérentes à l'exploitation de données réelles, souvent hétérogènes, incomplètes ou bruitées, et souligne l'importance cruciale des phases de prétraitement pour garantir la fiabilité des analyses.

L’analyse exploratoire réalisée à partir des annonces immobilières collectées a permis de dégager plusieurs tendances structurantes du marché immobilier français, notamment de fortes disparités régionales et locales en termes de prix au mètre carré. Les analyses par région et par ville ont mis en évidence une hétérogénéité marquée, confirmant l’intérêt d’une approche multi-échelle. L’étude des relations entre prix et surface a également montré la pertinence du recours à des indicateurs robustes, tels que la médiane, afin de limiter l’influence des valeurs extrêmes.

Le développement d’une application interactive sous Streamlit constitue un apport majeur du projet. Elle offre une interface intuitive permettant à l’utilisateur d’explorer les données, de filtrer les annonces selon différents critères et de visualiser les résultats sous forme de graphiques et de cartes. L’intégration d’une cartographie basée sur le géocodage des communes à l’aide de Geopy et du service Nominatim enrichit l’analyse en apportant une dimension spatiale fine, facilitant l’interprétation des dynamiques territoriales.

Ce projet présente néanmoins certaines limites. Les analyses reposent exclusivement sur les annonces disponibles sur les plateformes scrappées et ne constituent pas une représentation exhaustive du marché immobilier réel. De plus, l’absence de dimension temporelle ne permet pas d’étudier l’évolution des prix dans le temps. Malgré ces contraintes, le travail réalisé fournit une base solide pour l’exploration et la compréhension des mécanismes du marché immobilier.

Enfin, ce projet ouvre de nombreuses perspectives d’amélioration. Parmi celles-ci figurent l’intégration de données temporelles, l’enrichissement par des sources externes (données socio-économiques, énergétiques ou démographiques), ainsi que le développement de modèles prédictifs visant à estimer le prix d’un bien à partir de ses caractéristiques. L’application développée pourrait ainsi évoluer vers un véritable outil d’aide à la décision, tant pour les particuliers que pour les professionnels de l’immobilier.

1. Mericskay B, Demoraes F. Préparer et analyser les données de « Demandes de valeurs foncières » en open data : proposition d'une méthodologie reproductible. cybergeo [Internet]. 27 sept 2022 [cité 20 déc 2025]; Disponible sur: http://journals.openedition.org/cybergeo/39583

2. Ferrara E, De Meo P, Fiumara G, Baumgartner R. Web data extraction, applications and techniques: A survey. Knowledge-Based Systems. nov 2014;70:301-23.

3. Chen X, Biljecki F. Mining real estate ads and property transactions for building and amenity data acquisition. Urban Info. 23 nov 2022;1(1):12.

4. Yin Z, Goldberg DW, Lin B, Zhou B, Li D, Ma A, et al. Toward building next-generation Geocoding systems: a systematic review [Internet]. arXiv; 2025 [cité 20 déc 2025]. Disponible sur: https://arxiv.org/abs/2503.18888

5. Arbia G, Nardelli V. On Spatial Lag Models estimated using crowdsourcing, web-scraping or other unconventionally collected data. 2020 [cité 20 déc 2025]; Disponible sur: https://arxiv.org/abs/2010.05287

Projet réalisé par Constance KEITA et Guillaume PATIENT – Python avancé